

Score-функция и условная генерация

Оганов Александр Артурович

По материалам курса “Генеративные модели на основе диффузии”




Оглавление

- Вспоминаем DDPM
- Score-функция
- Score Identity
- Связь с условным математическим ожиданием
- Обучение
- Условная генерация

Основная идея

Диффузионные модели постепенно расшумляют изображение при заданном процессе зашумления.



Процесс зашумления — **Forward process**;
Процесс расшумления — **Backward process**.

DDPM обучение

Функция потерь:

$$D_{\text{KL}}\left(q_{0,\dots,T}(x_0, \dots, x_T) \parallel p_{0,\dots,T}^{\theta}(x_0, \dots, x_T)\right) \rightarrow \min_{\theta}.$$

Обучение на практике:

$$x_0 \sim \mathcal{D}, \quad \mathcal{D} \text{ — датасет};$$

$$t \sim \text{Uniform}(\{0, \dots, T\});$$

$$\varepsilon \sim \mathcal{N}(0, I);$$

$$x_t = A_t x_0 + B_t \varepsilon;$$

$$\mathcal{L} = \omega_t \|\varepsilon - \varepsilon_{\theta}(x_t, t)\|^2.$$

где A_t, B_t, ω_t — параметры, которые зависят от выбора VP или VE процесса. $\varepsilon_{\theta}(\cdot, \cdot)$ — модель предсказания шума.

Что выучит модель?

Шаг зашумления:

$$\mathbf{x}_t = A_t \mathbf{x}_0 + B_t \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I).$$

Значит: $\mathbf{x}_t \sim q_{t|0}(\mathbf{x}_t \mid \mathbf{x}_0) := \mathcal{N}(\mathbf{x}_t \mid A_t \mathbf{x}_0, B_t^2 I)$.

$$q_{t|0}(\mathbf{x}_t \mid \mathbf{x}_0) = \frac{1}{\mathcal{Z}} \exp \left(-\frac{\|\mathbf{x}_t - A_t \mathbf{x}_0\|^2}{2B_t^2} \right);$$

$$\log q_{t|0}(\mathbf{x}_t \mid \mathbf{x}_0) = - \left(\frac{\|\mathbf{x}_t - A_t \mathbf{x}_0\|^2}{2B_t^2} \right) - \log \mathcal{Z};$$

$$\nabla_{\mathbf{x}_t} \log q_{t|0}(\mathbf{x}_t \mid \mathbf{x}_0) = -\frac{\mathbf{x}_t - A_t \mathbf{x}_0}{B_t^2} = -\frac{\varepsilon}{B_t}.$$

Значит обучение на ε эквивалентно обучению на $\nabla_{\mathbf{x}_t} \log q_{t|0}(\mathbf{x}_t \mid \mathbf{x}_0)$, которую принято называть условной score-функцией.

DDPM генерация

Начало генерации:

$$\text{VP} : \mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I}),$$

$$\text{VE} : \mathbf{x}_T \sim \mathcal{N}(0, \sigma_T^2 \mathbf{I}).$$

Шаг генерации:

$$\mathbf{x}_{t-1} \sim p_{t-1|t}^{\theta}(\mathbf{x}_{t-1} \mid \mathbf{x}_t).$$

Вспомним:

$$p_{t-1|t}^{\theta}(\mathbf{x}_{t-1} \mid \mathbf{x}_t) := \mathcal{N}\left(\mathbf{x}_{t-1} \mid \tilde{A}_t \mathbf{x}_t + \tilde{B}_t \varepsilon_{\theta}(\mathbf{x}_t, t), \tilde{C}_t^2 \mathbf{I}\right),$$

где $\tilde{A}_t, \tilde{B}_t, \tilde{C}_t$ зависят от процесса зашумления.

Как получить идеальную генерацию?

Мы бы хотели знать $q_{t-1|t}(x_{t-1} | x_t)$, посмотрим чуть с другой стороны. Воспользуемся формулой Байеса:

$$q_{t-1|t}(x_{t-1} | x_t) = \frac{q_{t|t-1}(x_t | x_{t-1})q_{t-1}(x_{t-1})}{q_t(x_t)}.$$

Попробуем приблизительно посчитать $\frac{q_{t-1}(x_{t-1})}{q_t(x_t)}$:

$$\begin{aligned}\frac{q_{t-1}(x_{t-1})}{q_t(x_t)} &= \exp(\log q_{t-1}(x_{t-1}) - \log q_t(x_t)) = \\ &= \exp(\log q_{t-1}(x_{t-1}) - \log q_t(x_t)) \approx \\ &\approx \exp(\log q_t(x_{t-1}) - \log q_t(x_t)) = \\ &= \exp\left(\nabla_{x_t} \log q_t(x_t)^T (x_{t-1} - x_t) + o(\|x_{t-1} - x_t\|)\right).\end{aligned}$$

Мы свели задачу к вычислению $\nabla_{x_t} \log q_t(x_t)$, которую принято называть score-функцией.

Связь score-функции и условной score-функции

Постараемся понять как посчитать $\nabla_{x_t} \log q_t(x_t)$ через что-то более простое:

$$\begin{aligned}\nabla_{x_t} \log q_t(x_t) &= \frac{\nabla_{x_t} q_t(x_t)}{q_t(x_t)} = \frac{\nabla_{x_t} \int q_{t|0}(x_t | x_0) p_0(x_0) dx_0}{q_t(x_t)} = \\ &= \frac{\int \nabla_{x_t} q_{t|0}(x_t | x_0) p_0(x_0) dx_0}{q_t(x_t)}.\end{aligned}$$

Умножим и разделим на $q_{t|0}(x_t | x_0)$:

$$\int \nabla_{x_t} \log q_{t|0}(x_t | x_0) \frac{q_{t|0}(x_t | x_0) p_0(x_0)}{q_t(x_t)} dx_0.$$

Воспользуемся формулой Байеса:

$$\int \nabla_{x_t} \log q_{t|0}(x_t | x_0) q_{0|t}(x_0 | x_t) dx_0 = \mathbb{E}_{q_{0|t}} [\nabla_{x_t} \log q_{t|0}(x_t | x_0)].$$

Score Identity

$$\nabla_{x_t} \log q_t(x_t) = \mathbb{E}_{q_{0|t}} [\nabla_{x_t} \log q_{t|0}(x_t | x_0)] .$$

Представим, что p_0 дискретное распределение для трёх объектов, тогда для VE процесса:

$$p_0(x_0) = \frac{1}{3} \sum_{i=1}^3 \mathbb{I}[x_0 = x^{(i)}], \quad q_t(x_t) = \frac{1}{3} \sum_{i=1}^3 \mathcal{N}(x_t | x^{(i)}, \sigma_t^2) .$$

Получаем:

$$\nabla_{x_t} \log q_t(x_t) = \frac{1}{3} \sum_{i=1}^3 \nabla_{x_t} \log \mathcal{N}(x_t | x^{(i)}, \sigma_t^2) \cdot q_{0|t}(x^{(i)} | x_t) .$$

Score Identity: VP, VE

$$\nabla_{x_t} \log q_t(x_t) = \mathbb{E}_{q_{0|t}} [\nabla_{x_t} \log q_{t|0}(x_t | x_0)] .$$

Вспомним, что:

$$\nabla_{x_t} \log q_{t|0}(x_t | x_0) = -\frac{x_t - A_t x_0}{B_t^2} = -\frac{\varepsilon}{B_t} .$$

Для VP процесса:

$$\nabla_{x_t} \log q_{t|0}(x_t | x_0) = -\frac{\varepsilon}{\sqrt{1 - \bar{\alpha}_t}} .$$

Для VE процесса:

$$\nabla_{x_t} \log q_{t|0}(x_t | x_0) = -\frac{\varepsilon}{\sigma_t} .$$

В чём проблема?

$$\nabla_{x_t} \log q_t(x_t) = \mathbb{E}_{q_{0|t}} [\nabla_{x_t} \log q_{t|0}(x_t | x_0)] .$$

Мы **умеем** считать $\nabla_{x_t} \log q_{t|0}(x_t | x_0)$ и даже умеем приближать, но **не знаем** ничего про $q_{0|t}$.

Известно, что:

$$\phi(x) := \mathbb{E}_{p(y|x)} [y] = \arg \min_g \mathbb{E}_{p(y,x)} \|g(x) - y\|^2.$$

Следовательно:

$$\nabla_{x_t} \log q_t(x_t) = \arg \min_g \mathbb{E}_{q_{0,t}} \|g(x_t) - \nabla_{x_t} \log q_{t|0}(x_t | x_0)\|^2.$$

Связь функций потерь

$$\nabla_{x_t} \log q_t(x_t) = \arg \min_g \mathbb{E}_{q_{0,t}} \|g(x_t) - \nabla_{x_t} \log q_{t|0}(x_t | x_0)\|^2.$$

Если s — нейронная сеть с параметрами θ , то наша задача решить:

$$\mathbb{E}_{q_{0,t}} \|s_\theta(x_t, t) - \nabla_{x_t} \log q_{t|0}(x_t | x_0)\|^2 \rightarrow \min_{\theta}.$$

Если мы вспомним: $\nabla_{x_t} \log q_{t|0}(x_t | x_0) = -\frac{x_t - A_t x_0}{B_t^2}$, то получим что с точностью до константы мы можем обучать:

$$\mathbb{E}_{q_{0,t}} \|D_\theta(x_t, t) - x_0\|^2 \rightarrow \min_{\theta},$$

модель $D_\theta(x_t, t)$ часто называют моделью **денойзера**.

Что мы получили?

Теперь мы знаем, обучение моделей $\varepsilon_{\theta}(\cdot, \cdot)$, $D_{\theta}(\cdot, \cdot)$, $s_{\theta}(\cdot, \cdot)$ эквивалентно. Значит мы чуть больше узнали про тот объект, который должны получить. Например, что мы можем предсказывать изображение и добавить к функции потерь какую-либо оценку качества изображения или что нейронная сеть учит градиент некоторой функции.

Условная генерация

Рассмотрим более интересную для практики задачу — условную генерацию. Представим, что наша цель не просто сгенерировать изображение собаки, а изображение конкретной породы. Кроме того, для датасета есть разметка (какая порода на изображении).

Формально мы хотим генерировать не из $p_0(x_0)$, а из $p_0(x_0 | y)$, где y — желаемая порода.

Получается, по аналогии нам нужно использовать не $\nabla_{x_t} \log q_t(x_t)$, а $\nabla_{x_t} \log q_t(x_t | y)$.

Classifier guidance

Найдем $\log q_t(x_t | y)$:

$$q_t(x_t | y) = \frac{q_{t,y}(x_t, y)}{p_y(y)} = \frac{p_{y|t}(y | x_t) q_t(x_t)}{p_y(y)},$$

$$\log q_t(x_t | y) = \log p_{y|t}(y | x_t) + \log q_t(x_t) - \log p_y(y).$$

Откуда, $\nabla_{x_t} \log q_t(x_t | y) = \nabla_{x_t} \log p_{y|t}(y | x_t) + \nabla_{x_t} \log q_t(x_t)$.
Для $\log p_{y|t}(y | x_t)$ обучаем классификатор по зашумленным изображениям (шумный классификатор).

Можно усилить эффект условия если использовать:

$$(1 + \gamma) \nabla_{x_t} \log p_{y|t}(y | x_t) + \nabla_{x_t} \log q_t(x_t),$$

где $\gamma \geq 0$.

Classifier free guidance

Чем больше γ , тем лучше изображение соответствуют условию, но тем изображения меньше имеют разнообразия. При условной генерации получается выше качество изображений. Способ без обучения классификатора:

$$\begin{aligned}(1 + \gamma) \nabla_{x_t} \log p_{y|t}(y | x_t) + \nabla_{x_t} \log q_t(x_t) &= \\&= \nabla_{x_t} (\log p_{y|t}(y | x_t) + \log q_t(x_t)) + \gamma \nabla_{x_t} \log p_{y|t}(y | x_t) = \\&= \nabla_{x_t} \log q_{t|y}(x_t | y) + \gamma (\nabla_{x_t} \log q_{t|y}(x_t | y) - \nabla_{x_t} \log q_t(x_t)) .\end{aligned}$$

Тогда мы можем учить s_θ с учетом y , а в случае отсутствия условия использовать метку $\emptyset$:

$$s_\theta(x_t, t, y) + \gamma (s_\theta(x_t, t, y) - s_\theta(x_t, t, \emptyset)) .$$

Генерация по тексту

Задача генерации изображения по тексту называется text-to-image генерация. У нас имеется выборка аннотированных изображений, требуется генерировать изображения по описанию. Основная задача в том, что условий не конечное количество, значит мы не сможем использовать классификатор.

Для учета текста внутри $s_{\theta}(\cdot, \cdot, \cdot)$ есть множество способов. Обычно, в архитектуре нейронной сети присутствуют слои внимания. Мы можем использовать эмбединги из текстовой модели внутри них для учитывания текста. Часто это модели CLIP или T5.

Способы оценки качества

Мы хотим от text-to-image модели качественной генерации и соответствия изображения тексту. Мы будем использовать SDXL. При этом даже на простых примерах сложно сказать, где текст учитывается лучше.

Guidance = 1
CLIP Score = 0.294



Guidance = 2
CLIP Score = 0.289




Guidance = 5
CLIP Score = 0.288




Guidance = 7.5
CLIP Score = 0.282



Guidance = 10
CLIP Score = 0.279




Guidance = 15
CLIP Score = 0.284



Guidance = 20
CLIP Score = 0.287



Guidance = 40
CLIP Score = 0.264



prompt = A horse

CLIP Score

Мы можем оценить похожесть изображения тексту с помощью модели CLIP и других моделей. CLIP не всегда работает хорошо.

Guidance = 1
CLIP Score = 0.361



Guidance = 2
CLIP Score = 0.384



Guidance = 5
CLIP Score = 0.375



Guidance = 7.5
CLIP Score = 0.379



Guidance = 10
CLIP Score = 0.374



Guidance = 15
CLIP Score = 0.370



Guidance = 20
CLIP Score = 0.377



Guidance = 40
CLIP Score = 0.366



prompt = A steampunk airship sailing over volcanic clouds, painted in classic romanticism landscape style combined with comic book heavy ink outlines, rich emotional skies contrasted with bold crisp paneling

Оценка качества

Для оценки качества мы можем использовать FID;

Для оценки соответствия условию мы можем использовать CLIP Score;

Для оценки качества сложных изображений можно использовать нейронные сети натренированные на вкус человека (например, HPS);

Для точно оценки качества можно использовать исследование пользователей (user study).